

PREDICTION TASK Qual é o tipo de tarefa? Para qual entidade as previsões são feitas? Quais são os possíveis resultados para prever? Quando os resultados são observados? Classificação binária supervisionada. Entidade: cliente individual (customerID). Resultados possíveis: Churn = Sim / Não. Resultado observado como snapshot estático neste dataset; em produção seria observado no evento de cancelamento/não renovação do contrato, registrado pelo sistema de billing/CRM. (rascunho — validar interpretação com o grupo)	DECISIONS Como as previsões são tornadas em recomendações acionáveis ou decisões para o usuário final? (Mencione parâmetros do processo / aplicação para isso.) As previsões geram um score de risco de churn por cliente. Clientes acima de um limiar de risco definido são adicionados a uma lista de "em risco" consumida pela equipe de retenção/CRM. A ação específica de retenção (desconto, upgrade, contato proativo) é escolhida manualmente pela equipe com base no segmento do cliente — a seleção da ação está fora do escopo do modelo neste MVP.	VALUE PROPOSITION Quem é o beneficiário final, e quais são as dores específicas a serem tratadas? Como a solução ML integrará com a workflow, e por quais interfaces de usuário? Uma operadora de telecom está perdendo clientes (churn) em ritmo acelerado. A liderança precisa identificar, ANTES do cancelamento, quais clientes têm alto risco de saída, para que a equipe de retenção possa agir (desconto, upgrade, contato proativo). Beneficiário final: equipe de retenção/CRM, apoiada pela liderança comercial visando reduzir a taxa mensal de churn.	DATA COLLECTION Como (ou onde) o set inicial de entidades e resultados são originados? (e.g., database extracts, API pulls, manual labeling)? Quais estratégias estão em vigor para atualizar dados continuamente enquanto controlamos custos e mantemos a "novidade" dos dados? Dados iniciais vindos do dataset público IBM Telco Customer Churn, usado como proxy para um extrato real de produção de billing + CRM. Snapshot estático e único para este projeto acadêmico — sem atualização contínua implementada. Em uma implantação real, um job de ETL periódico (ex.: diário/semanal) do banco de billing atualizaria o dataset; documentado como trabalho futuro. (rascunho)	DATA SOURCES Onde podemos pegar dados das entidades e resultados observados? (Mencione tabelas de database internas e externas ou métodos de API). Telco Customer Churn (IBM), dataset tabular público. Fonte: github.com/IBM/telco-customer-churn-on-icp4d, data/Telco-Customer-Churn.csv. 7.043 registros, 21 colunas (a confirmar contagem exata após EDA).
IMPACT SIMULATION What are the cost/gain values for (in)correct decisions? Which data is used to simulate pre-deployment impact? What are the criteria for deployment? Are there fairness constraints? Valores de custo/ganho (ilustrativos, substituir por números reais quando disponíveis): oferta de retenção ≈ R\$50/cliente; cliente perdido (LTV) ≈ R\$1.200/cliente. Custo de negócio = (falsos negativos × custo de perder um cliente) + (falsos positivos × custo de uma oferta desperdiçada). Simulado no conjunto de teste (held-out). Critério de deploy: o modelo deve superar as baselines nessa função de custo, não apenas em AUC-ROC. Restrição de fairness: monitorar a diferença de recall/FPR entre gênero e SeniorCitizen; sinalizar se a disparidade for > 10pp. (rascunho — precisa de input real de negócio do grupo/stakeholders)	MAKING PREDICTIONS Are predictions made in batch or in real time? How frequently? How much time is available for this (including featurization and decisions)? Which computational resources are used? Endpoint de API síncrono em tempo real (FastAPI /predict), sob demanda a cada interação com o cliente. Rollout em batch (diário/semanal) discutido como alternativa, decisão formal na Etapa 4 (arquitetura de deploy). Orçamento de tempo: p95 < 300ms incluindo featurização. Computação: uma instância pequena de CPU, sem necessidade de GPU. (rascunho)		BUILDING MODELS How many models are needed in production? When should they be updated? How much time is available for this (including featurization and analysis)? Which computation resources are used? 3 candidatos comparados, todos em Scikit-Learn — Regressão Logística (baseline), Random Forest/ensemble (baseado em árvores) e MLPClassifier (rede neural simples). O de melhor desempenho é escolhido como campeão e salvo com joblib. O rastreamento de experimentos é leve — uma tabela comparativa (notebook/planilha) é suficiente; MLflow é opcional, não obrigatório. Retreinamento fora de escopo para este dataset estático, recomendado mensal/trimestral em produção. Os treinos rodam em uma sessão padrão de notebook/CI, apenas CPU.	FEATURES What representations are used for entities at prediction time? What aggregations or transformations are applied to raw data sources? Candidatas: tenure, tipo de contrato, forma de pagamento, serviços assinados (internet, streaming, suporte técnico), cobranças mensais/totais. Representação: features numéricas escaladas; features categóricas codificadas em one-hot/ordinal; binárias Sim/Não mapeadas para 0/1. Dataset já agregado no nível de cliente — não é necessária agregação entre entidades. Features de engenharia candidatas a explorar: faixas de tenure, contagem de serviços assinados. (rascunho)
MONITORING Quais métricas e KPIs são usadas para acompanhar o impacto da solução de ML após o deploy, tanto para usuários finais quanto para o negócio? Com que frequência devem ser revisados? SLOs: latência p95 < 300ms, /health retornando 200 continuamente, throughput dimensionado para a base ativa de clientes. KPIs pós-deploy: AUC-ROC/PR-AUC/F1 ao vivo conforme novos rótulos chegam, métrica de custo de negócio, data drift em tenure/cobranças mensais, volume de previsões. Revisão mensal, ou quando um novo lote rotulado chegar; alertar se AUC-ROC cair > 0.03. (rascunho)				